

Development of Brain Tumor Classification Model Using ViT

곽도현

Abstract

뇌종양은 전체 종양 중 세 번째로 많이 발생하는 종양으로 CT, MRI와 같은 의료 영상으로 진단한다. 의료영상 판독에 영상의학 전문의의 수동분류가 반드시 필요하여 진단까지 다소 시간이 소요되고, 영상의학 전문의의 지역 불균형으로 인해 수도권 제외 지역의 전문의의 업무 부담이 우려된다. 이러한 문제점을 해결하고자 인공지능 기술을 적용한 임상 진단 보조 시스템인 CAD (Computer-Aided Diagnosis)가 개발되었고, 의료 영상 분류에 상당한 효능이 입증되었다. CAD 시스템에서 CNN (Convolution Neural Network) 기반 모델의 성능이 앞서고 있지만 최근 ViT (Vision Transformer) 모델을 이용한 분류 모델 개발 연구가 진행되고 있다. 이 연구에서는 ViT를 사용한 의료 영상 분류 효능과 뇌 MRI 이미지 분류 정확도를 분석하기 위해 뇌 MRI 이미지를 ViT를 사용하여 분류하는 모델을 개발하였고, 모델은 이미지를 Glioma, Meningioma, Pituitary, No tumor 총 4개의 Class로 분류한다. 개발된 모델은 최고 성능 accuracy 77.23%를 보이며, Glioma, No tumor의 경우 recall 값이 0.7 이상으로 나타났다. 연구를 통해 ViT가 의료 영상 분류에 효과가 있는 모델임을 입증하였고, 뇌 MRI 이미지 분류 문제에 적용 가능한 모델임을 알 수 있었다.

1. Introduction

National Cancer Institute에 따르면 뇌종양은 뇌 조직에서의 비정상적인 세포의 성장으로 정의된다 [1]. 비정상적으로 성장한 뇌종양은 뇌 조직의 크기를 감소시켜 뇌의 신경망에 많은 손상을 일으켜 결과적으로 뇌의 활동을 방해한다. 뇌종양은 악성과 양성으로 나눌 수 있고, 부위에 따라 일반적으로 발생하는 뇌종양의 종류는 신경아교종 (Glioma), 수막종 (Meningioma), 뇌하수체종 (Pituitary) 이다. 신경아교종은 신경아교 조직과 척수 부위에서 자라는 뇌종양의 한 종류이고, 수막종은 뇌와 척수를 보호하는 막 부위에서 자라는 종양의 일종이며, 뇌하수체종은 뇌하수체 부위에서 자란다 [2]. 뇌종양은 인체에서 발생하는 전체 종양 중 세 번째로 많이 발생하며 (약 10%) 국제 인구 통계자료에 의하면 매년 인구 10만 명당 10명 정도의 새로운 환자가 발생한다 [3]. 건강보험심사평가원 통계에 따르면 양성·악성 뇌종양으로 치료받는 환자가 2017년 4만 9001명에서 2021년에는 6만 3787명으로 집계되었다 [4].

현재 뇌종양의 진단은 임상 및 방사선 정보를 사용하여 판단한다. 뇌종양은 자기 공명 영상 (Magnetic Resonance Imaging, MRI) 및 컴퓨터 단층 촬영 (Computed tomography, CT) 과 같은 의료 영상 기술을 사용하여 뇌 영상을 촬영하고 전문의에 의해 진단된다. 이처럼 MRI와 CT는 뇌종양 환자 평가에 핵심적인 기술이지만, 전문의를 거쳐 종양의 유무를 분류하므로 많은 시간이 소요된다는 한계점이 있다 [5]. 또한 영상의학과 전문의 인력 문제도 있다. 최근

건강보험심사평가원이 시행하고자 하는 CT·MRI·PET (Positron Emission Tomography) 영상 검사 적정성 평가 항목 중 24시간 이내 영상의학과 전문의 판독 완료율 항목을 두고 의료계가 ‘인력 부족’의 문제를 제기하였고 [6], 국민건강보험공단에서 시행한 건강보험통계에 따르면 전체 영상의학과 전문의 4,159명 중 서울이 1,415명으로 전체의 34%를 차지할 만큼 [7] 수도권에 전문의 수가 집중되는 경향을 보인다. 이와 같은 현상으로 인해 지방에서의 영상의학과 전문의가 판독해야 하는 건수의 부담이 늘고 오진 발생과 같은 2차적인 문제가 발생할 수도 있다.

이와 같은 문제점을 보완하고자 인공지능 기술의 이점을 활용하여 이미지 분석을 통해 뇌종양의 분류 및 탐지하는 컴퓨터 보조 진단 (Computer-Aided Diagnosis, CAD) 시스템 개발이 활발히 이루어지고 있다. CAD는 전문의가 종양을 조기 발견할 수 있게 하고 분류 정확성을 높이는 데 도움이 될 수 있다. 뇌종양을 분류하고 탐지하는 모델에 사용하는 인공지능 기술은 인공신경망 (Artificial Neural Network), 서포트 벡터 머신 (Support Vector Machine), 합성곱 신경망 (Convolution Neural Network, CNN) 등이 있다 [2].

이 중 CNN은 훈련 과정 전에 전처리나 특징 추출이 필요하지 않다는 장점이 있어 의료 영상, 특히 MRI 및 CT를 기반으로 한 질병 진단 분야에 널리 사용되고 있다. Ali M.A. *et al*, 2019에서 뇌종양 분류에 CNN을 사용한 결과 신경아교종, 수막종, 뇌하수체종 3종류의 뇌종양 분류 성능이 최고 98%로 나타났다. 이 연구 결과를 통해 CNN은 의료 영상 분류에 상당한 효과가 있는 모델임을 알 수 있다.

최근에는 자연어처리에서 주로 사용되는 Trasformer를 이미지에 적용한 Vision Transformer (ViT) 모델이 개발된 후 의료 영상 분석에 ViT 모델을 적용하는 시도가 이루어지고 있다. Mondal, A.K. *et al*, 2022 [8] 이 연구는 ViT 모델을 이용하여 X-ray 이미지 분석을 통해 COVID-19와 폐렴의 분류 모델을 개발하였고, Gheflati, B. *et al*, 2021 [9] 이 연구에서는 초음파 이미지를 ViT로 분석하여 유방암을 분류하였으며 CNN보다 ViT가 더 우수한 성능을 보인다고 하였다.

앞선 선행 연구 결과를 토대로 뇌 MRI 이미지에 ViT 모델을 적용하여 뇌종양 종류를 분류하는 모델을 개발하고자 한다. 이 연구를 통해 ViT 모델이 4가지 종류 (신경아교종, 수막종, 뇌하수체종, 종양없음) 의 종양을 잘 구분하는지 확인할 것이다.

2. Methods

2-1. Dataset

뇌종양 분류에 사용한 모델은 kaggle의 Brain Tumor MRI Dataset을 사용하였다 [10]. MRI 이미지는 각 Class 마다 시상면 (Sagittal), 관상면 (Frontal), 횡단면 (Horizontal) 3가지 종류의 단층면 이미지로 구성되어 있다. Glioma, Meningioma, Pituitary, No Tumor 4가지 class로 분류한 사람 뇌 MRI 이미지 7022장으로 이루어져 있으며, 그 중 학습 데이터 5712장, 테스트 데이터 1311장으로 구성되어있다. 학습, 테스트 데이터 각각의 class 별 이미지 수는 아래 표와 같다.

Table 1. Train, Test Class 별 이미지 개수

Class	Train	Test
glioma	1,321	300
meningioma	1,339	306
pituitary	1,457	300
notumor	1,595	405
Total	5,712	1,311




Figure 1. Class 별 이미지 예시

2-2. 전처리

kaggle 데이터셋으로부터 받은 이미지는 Train, Test 폴더 하위에 각 Class 별로 이미지 폴더가 있고 그 안에 이미지가 있기 때문에 하나의 변수에 이미지를 묶는 과정이 필요했다. 따라서 os 모듈을 사용하여 Train, Test의 각 Class 폴더의 이미지를 불러와 하나의 list X 변수에 append 하였다. 이미지를 불러오는 과정에서 이미지의 크기를 통일하기 위해 (512, 512, 3)로 변환하였다.

label 데이터는 이미지를 불러오는 과정에서 해당 폴더명을 list y에 append 하였다. string형인 label을 int형으로 변환하기 위해서 뇌종양 종류 명을 담고 있는 길이 4의 labels list를 생성한 후 index를 이용하여 y의 label 요소의 index를 받아와 int형으로 변환하였다. Class 별 int형 라벨은 다음과 같다.

[glioma : 0, meningioma : 1, no tumor : 2, pituitary : 3]

이렇게 형성한 X, y 데이터는 ndarray 형태로 변환하였다. 변환된 ndarray에는 이미지가 Class 별로 순서대로 append 되었기 때문에 scikit learn의 shuffle 모듈을 사용하여 데이터를 섞어 주었고, Train 데이터에서 5700개, Test 데이터에서 1300개를 sampling 하였다. 이 과정은 추후 모델 설계 과정에서 reshape에 error가 발생하여 Train, Test 데이터 수를 100의 자리로 맞춰줘야 하기 때문에 수행되었다. 최종 input 데이터 형태는 다음 표와 같다.

Table 2. 최종 Train, Test 데이터의 크기와 type

Variable	shape	type
X_train	(5700, 512, 512, 3)	numpy.ndarray
X_test	(1300, 512, 512, 3)	numpy.ndarray
y_train	(5700,)	numpy.ndarray
y_test	(1300,)	numpy.ndarray

2-3. 모델 설계

① Vision Transformer Structure




Figure 2. ViT 모델 구조도

Vision Transformer (ViT)는 전체 이미지를 patch 단위로 나눈 후 분석하는 모델로 전체 이미지가 sequence라면 patch는 sequence를 이루는 단위라고 할 수 있다. 이미지의 크기 (H, W, C)라면 이를 (P,P)개의 patch로 나뉘었을 때, 이미지는 크기 (P, P, C)의 patch N개로 나누어 진다 ($N = \frac{HW}{P^2}$). N개의 patch로 나눈 이미지는 Linear Projection을 통해 차원 축소가 이루어지는데 이 연구에서는 차원을 $D=972$ 로 유지하였다. ViT는 이미지 분류를 위해 sequence에 Class Token을 sequence의 맨 앞에 concat으로 붙여주었다. 이 Class Token이 Transformer Encoder에 들어가서 학습을 수행하면서 모든 sequence의 정보가 Class Token에 누적된다. 따라서 Class Token을 이용하여 이미지의 Classification을 수행할 수 있게 된다. Class Token을 붙임으로써 전체 sequence의 길이는 $N + 1$ 이 된다. 이렇게 만들어진 sequence에 position embedding을 더해주어 sequence가 position 정보를 가질 수 있게 한다. 최종적으로 Transformer에 들어가는 input의 크기는 $(N+1, D)$ 가 된다. Transformer Encoder에서는 Multi Head Attention을 사용하여 Class Token에 이미지 정보를 누적하고 Transformer Encoder의 output으로부터 Class Token만 사용하여 Classification을 진행한다.

② Resize Image & Make Patches

모델 개발 과정에서 학습 속도 개선을 위해 이미지 크기를 조정하였다. input값과 변경할 이미지의 크기를 입력값으로 받아 이미지 크기를 (324, 324)로 줄여주었다.

이후 이미지로부터 (18, 18) 크기의 patch로 이미지를 나눠주어 총 324개의 patch가 형성되었다. patch로 나뉜 이미지를 sequence의 형태로 만들어주기 위해 3차원으로 이미지를 reshape 하였고, 위 과정을 수행한 output 이미지의 크기는 (batch size, patch 개수, patch dimension)이다. patch dimension은 $18 * 18 * 3$ ($P^2 * C$) 로 972이다.

③ Linear Projection, Class Token, Position Embedding

앞선 과정의 output 이미지를 linear projection 통과시킨 projection 이미지를 생성하였다. 그런 다음 Class token을 생성하였다. Class token은 add_weight를 사용하여 (1, 1, patch의 dimension) 크기의 학습 가능한 랜덤한 값의 Class token을 생성하였다. 그리고 나서 Class token과 projection output을 concat 하여 이미지 patch sequence 앞에 Class token이 붙도록 하였다.

마지막으로 position embedding은 Transformer의 input으로 들어가게 되는 sequence의 position의 정보를 주기 위해서 수행된다. patch 개수에 class token 1개가 붙어 총 325 길이의 position을 생성하고 output dimension이 patch dimension이 되도록 Embedding을 수행한다. 최종적으로 (batch size, 325, 972) 크기의 output이 나온다.

concat한 이미지 sequence와 position embedding의 결과를 더해주어 최종 Transformer Encoder의 input 데이터가 만들어진다.

④ Transformer Encoder




Figure 3. Transformer Encoder의 구조도. Transformer Encoder에서 L은 Transformer Encoder Layer 개수이며, 이 연구에서는 L을 3으로 설정하였다.

위 그림과 같이 Transformer Encoder가 구성되고 Transformer Encoder는 총 3번 수행하였다. Multi Head Attention과 Multi Layer Perceptron (MLP) 을 수행하기 전에 Layer Normalization을 통과하고 각각의 output에 Residual을 연결하였다.

Multi Head Attention은 이미지 sequence의 patch를 split_heads 함수를 사용하여 patch dimension을 head 개수 (num_heads = 18) 로 나누고 각각에 대한 Scaled Dot Product Attention을 수행한 결과를 concat한 뒤 Linear 통과한 결과를 return 해주었다.

MLP는 dimension이 972로 유지되도록 Dense 개수를 972개로 하였고 activation function은 GELU를 적용하였다. Dense 이후에는 Dropout layer를 적용하였고 dropout rate는 0.2를 적용하였다.

⑤ Classifier

Transformer Encoder의 최종 output의 첫 번째 값 즉 class 토큰을 representation vector로 사용하여 hidden layer 486, 216의 MLP를 통과시켰다. 그리고 난 후 softmax를 activation function으로 사용하여 이미지를 분류하였다.

2-5. 학습 파라미터

모델의 최적화 함수는 Adam을 사용하였고, label 데이터에 one hot encoding을 수행하지 않았기 때문에 loss function은 SparseCategorical Cross entropy를 사용하였다. 평가지표는 accuracy를 사용하였다. batch size 100을 적용하여 미니 배치 학습을 시켰고 epoch는 100회로 수행하였다.

3. Results

모델 학습 결과 validation data에 대한 Accuracy 최고값은 77.23%로 나타났다.




Figure 4. Model Loss Graph (Left), Model Accuracy Graph (Right)

Accuracy와 Loss 변화 그래프를 그려봤을 때 초기 epoch에 급격히 성능이 좋아지고 이후에는 요동치는 형태를 보이지만 전반적으로 70% 대의 accuracy를 유지한다.

Table 3. Classification report 결과

평가 항목	precision	recall	f1-score
glioma	0.73	0.82	0.77
meningioma	0.49	0.44	0.46
pituitary	0.91	0.94	0.69
no tumor	0.75	0.56	0.83

scikit learn의 classification_report를 사용하여 평가지표 결과를 살펴보고, 실제 positive 중 올바르게 예측한 값인 recall 지표에서 glioma, no tumor의 경우 recall 값이 약 0.7 이상으로 높게 나오지만 meningioma의 경우 0.44으로 매우 저조한 성능을 보인다.




Figure 5. Confusion Matrix

confusion matrix 결과를 보았을 때 no tumor의 경우 상당히 좋은 예측 성능을 보이고, 상대적으로 meningioma는 정확히 예측한 값보다 예측이 실패한 경우가 더 많다는 것을 알 수 있다.

4. Discussion

이 연구에서 ViT를 적용하여 뇌종양 MRI 이미지를 4가지 Class (glioma, meningioma, pituitary, no tumor) 로 분류하는 모델을 개발하였다. Validation 데이터에 대한 모델의 최고 accuracy는 77.23%로 나타났으며, 평균적으로 70% accuracy의 성능을 보인다.




Figure 6. Misclassification Image in Class meningioma

이미지 Class 별 분류 결과는 Table 3, Figure 5에서와 같이 meningioma에서 recall 값이 다른 Class보다 낮고 no tumor로 분류되는 경우가 상당수가 있음을 보였다. 이는 이미지를 patch 단위로 나누게 되면서 전체 형태학적 특징을 보지 못했기 때문이라고 생각하였다. 그리고 Transformer Encoding 과정을 3회만 수행하였기 때문에 sequence 간의 정보가 더 많이 섞이지 못한 것도 영향을 주었을 것이라 생각하였다.

이미지를 학습하는 과정에서 hyper parameter 조절, 이미지 patch 크기 조정 등을 수행하여 결과를 비교하는 과정이 수행되지 않아 어떤 조건에서 ViT가 더 좋은 성능을 보이는지 확인하지 못하였다. 추후 연구에서는 다양한 모델을 설계하고 비교함으로써 ViT의 성능을 높일 수 있는지 연구할 예정이다. 또한 전체 형태학적 특성을 보는 CNN 모델과의 성능을 비교하는 연구도 진행하고자 한다.

연구 결과를 보았을 때 ViT를 이용한 뇌종양 MRI 이미지 분류는 굉장히 좋은 성능은 아니지만 ViT 모델이 뇌종양을 분류에 효과가 있는 것으로 나타났다. 추후 연구를 통해 ViT의 성능을 강화하게 되면 영상의학 분야에서 1차 진단을 보조하는 도구로서 사용될 수 있을 것이고 진단 속도 향상과 영상의학 전문의 부담을 낮출 수 있을 것이다.

5. Conclusion

ViT 모델이 의료 영상 분류에 얼마나 좋은 성능을 가지며 뇌 MRI 이미지를 잘 분류할 수 있는지 검증하기 위해서 이 연구를 진행하였다. ViT 모델과 MRI 이미지 데이터를 사용하여 뇌종양을 4개의 Class로 분류하는 모델을 개발한 결과 Accuracy가 최고 77.23%를 보였으며 평균적으로 70% accuracy 성능을 보였다. 각 Class 분류 결과를 보았을 때 meningioma를 정확히 분류한 횟수보다 다른 Class로 분류되는 경우가 더 높게 나타났다. 이는 ViT 모델의 특성상 이미지를 patch로 분리하게 되면서 이미지 전체의 형태학적 특성을 보지 못했기 때문이라고 판단하였다. 추후 연구에서는 추가적인 이미지 전처리, 학습 파라미터 조정과 CNN 모델과의 비교를 통해 뇌종양 분류 문제에서 ViT 모델과의 성능을 비교할 것이다. ViT 모델의 성능이 강화되면 영상의학 분야의 보조도구로서 ViT 모델을 사용한 소프트웨어를 적용할 수 있을 것이며 진단 속도 향상과 영상의학과 전문의의 부담을 낮출 수 있을 것으로 기대된다.

References

- [1] National Cancer Institute
<https://www.cancer.gov/publications/dictionaries/cancer-terms/def/brain-tumor>
- [2] Ali Mohammad Alqudah *et al*, 2019, Brain Tumor Classification Using Deep Learning Technique – A Comparison between Cropped, Uncropped, and Segmented Lesion Images with Different Sizes, International Journal of Advanced Trends in Computer Science and Engineering, 8(6)
- [3] 대학뇌종양학회. https://www.braintumor.or.kr/public/infor/sub2_1.php
- [4] 보건의료빅데이터개방시스템, 국민관심질병통계
<http://opendata.hira.or.kr/op/opc/olapMfrnIntrslInslInfo.do>
- [5] Biratu, E.S. *et al*, 2021, A survey of brain tumor segmentation and classification algorithms. J.Imaging
- [6] 심평원 CT·MRI·PET 영상검사 적정성 평가 소식에 영상의학과 업무 부담 '우려'
<https://m.medigatenews.com/news/1154831443>
- [7] 시군구별 전문과목별 전문의 인력현황
https://kosis.kr/statHtml/statHtml.do?orgId=354&tblId=DT_HIRA4S&conn_path=l2
- [8] Mondal, A.K. *et al*, 2022 A.P. xViTCOS: Explainable Vision Transformer Based COVID-19 Screening Using Radiography. *IEEE Transl. Eng. Heal. Med.*
<https://doi.org/10.1109/JTEHM.2021.3134096>.
- [9] Gheflati, B. *et al*, 2021, Vision transformers for classification of breast ultrasound images. DOI : <https://doi.org/10.48550/arXiv.2110.14731>.
- [10] Brain Tumor MRI Dataset. Msoud Nickparvar. Kaggle.
<https://www.kaggle.com/datasets/masoudnickparvar/brain-tumor-mri-dataset>